Cloud Infrastruktur MovieMatch

Autoren: Flavio Müller, Ronny Schneeberger
Ort, Datum: 05.01.2023, Brugg-Windisch

Inhaltsverzeichnis

Einleitung

Dieses Dokument beschreibt die Cloud Infrastruktur von MovieMatch. Es entstand im Rahmen des Studienganges Data Science and der Fachhochschule Nordwestschweiz. Es wird die Aufgabenstellung der Minichallenge 2 des Moduls *Cloud Infrastructure and Computing* bearbeitet. Es soll eine Cloud-API für cognitive services implementiert werden. Nebst der API selbst soll ein Monitoringsystem programmiert werden, welches die Kosten der eingesetzten Cloudservices überwacht.

Der Code für die verschiedenen Services ist in folgendem Git-Repository abgelegt: https://github.com/ronnyfhnw/cic-mc2

Vorstellung MovieMatch

MovieMatch ist ein Service, welcher Filmempfehlungen erstellen kann. MovieMatch entstand im Rahmen der Challenge *cds1 – Tinder for Movies*. Die Challenge verlangt ein Recommendersystem, welches Empfehlungen für Filme erstellen kann. Das Endprodukt ist ein Service, welcher Nutzerprofile erstellt und Empfehlungen

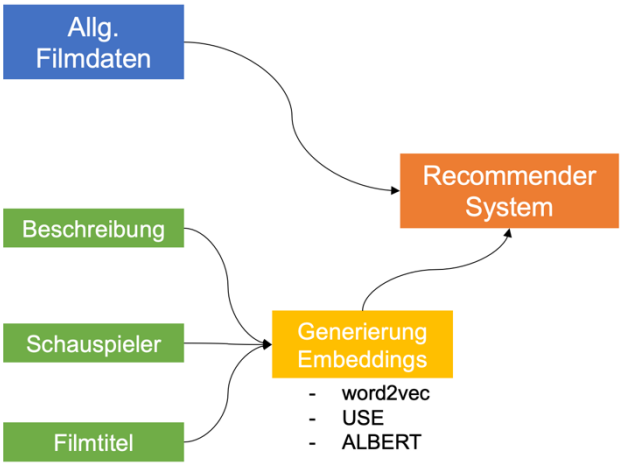

Abbildung 1, Aufbau Recommender System

abgibt. Die Publikation dieses Service verbinden wir mit der Minichallenge für das Modul *Cloud Infrastructure and Computing*.

Das Recommendersystem, welches von MovieMatch verwendet wird, ist aus mehreren Teilen aufgebaut. Die Itemmatrix wird mit Metadaten und Embeddings der Filmbeschreibungen, Schauspieler und Titel erstellt.
Wie bereits erwähnt, muss MovieMatch Nutzerprofile erstellen. Das System muss die Präferenzen des Benutzers kennenlernen. Dazu werden dem Benutzer verschiedene, zufällige Filme vorgeschlagen, die er bewerten kann. Nachdem der User zehn verschiedene Filme bewertet hat, bekommt er Empfehlungen vorgeschlagen.

Da die Minichallenge verlangt, dass ein Cognitive Service in der Infrastruktur enthalten ist, wurde MovieMatch um ein Feature reicher. Der Benutzer von MovieMatch soll mittels Sprachaufnahme einen Film beschreiben, den er gerne

sehen möchte. Auf diese Sprachaufnahme soll er Empfehlungen erhalten. Dies wird wie folgt umgesetzt: Die Sprachaufnahme wird an den Speech-to-text (speech-to-text) Service von Azure geschickt, um die Sprachaufnahme in Text umzuwandeln. Aus diesem Text wird mit einem Sprachmodell ein Embedding generiert. Schliesslich werden die Distanzen des Embeddings der Sprachaufnahme zu den Embeddings der Filmbeschreibungen berechnet. Die kürzesten Distanzen werden dem User als Empfehlungen vorgeschlagen.

MovieMatch wird als Webservice zur Verfügung gestellt. Er ist unter folgender URL erreichbar: www.moviematch.ch.

Vorstellung Infrastruktur

In diesem Kapitel werden die einzelnen Services vorgestellt, die von MovieMatch verwendet werden. Am Ende des Kapitels ist ein Diagramm der Infrastruktur abgebildet.

MovieMatch Frontend - A

Das Frontend besteht aus einer Angular 15 Single Page Application. Diese wird als statische Website auf einem Azure Storage Container gehosted und via Azure Content Delivery Network verteilt. Um auf das Mikrofon des Endgerätes zugreifen zu können muss die Website über HTTPS erreicht werden. Dies wird mit einem Reverse Proxy von Cloudflare erreicht.

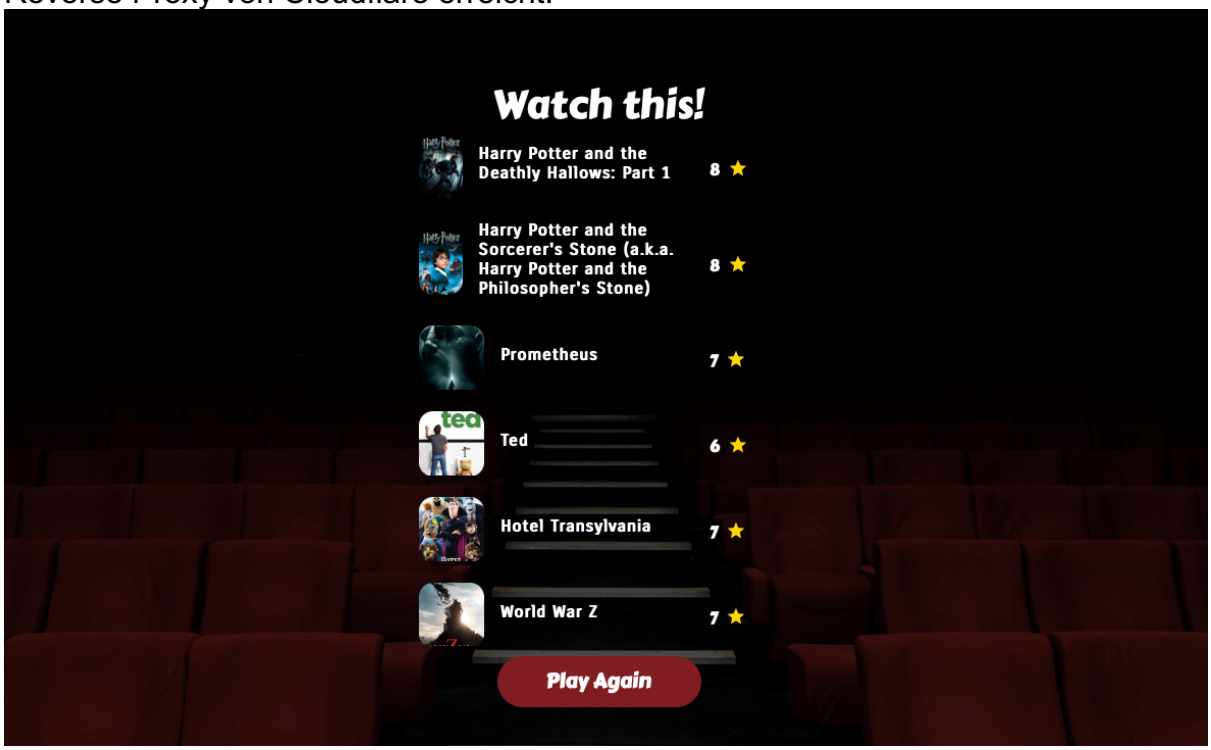

Abbildung 2: Moviematch Frontend

Azure Kubernetes Service - B

Der Kubernetes Cluster bildet das Herzstück der Infrastruktur. Er beinhaltet die Middleware, den cic-watcher und den cic-logger. Alle Anfragen auf diese drei Workloads werden von einem nginx Ingress Controller geroutet. Auch hier wurde

wieder ein Reverse Proxy von Cloudflare davor geschaltet, um die Webschnittstellen über HTTPS aufrufen zu können.

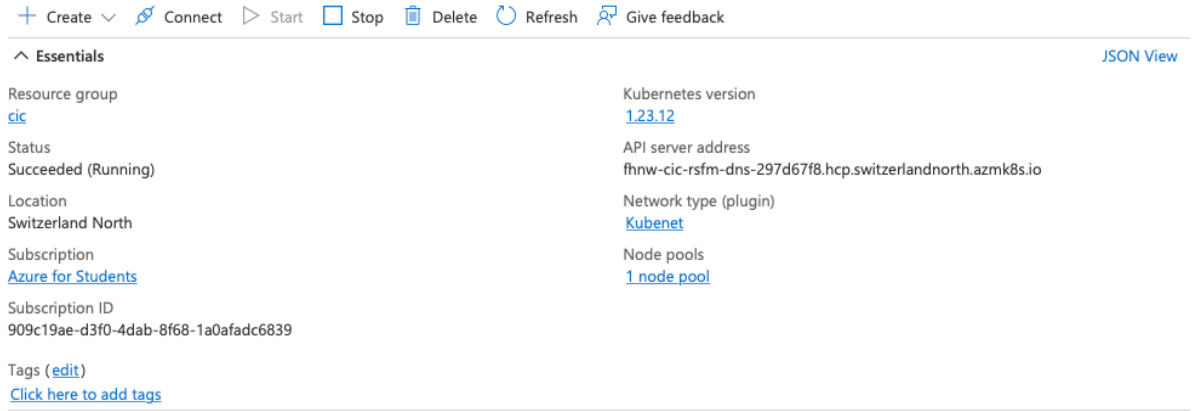

Abbildung 3: Konfiugration des Kubernetes Clusters

Ingress Controller - C

Der Ingress Controller wurde auf (https://api.moviematch.ch) gemappt und verteilt alle Anfragen basierend auf der Route an die drei verschiedenen Workloads. Der Ingress Controller bildet den einzigen Einstiegspunkt in den Kubernetes Cluster.

Name	Namespace	Status	Type	Cluster IP	External IP	Ports
kubernetes	default	Ok	ClusterIP	10.0.0.1		443/TCP
kube-dns	kube-system	Ok	ClusterIP	10.0.0.10		53/UDP,53/TCP
metrics-server	kube-system	Ok	ClusterIP	10.0.112.240		443/TCP
ingress-nginx-controller	ingress-basic	Ok	LoadBalancer	10.0.253.60	20.250.58.138	80:32368/TCP,4...
ingress-nginx-controller...	ingress-basic	Ok	ClusterIP	10.0.61.211		443/TCP
middleware	ingress-basic	Ok	ClusterIP	10.0.47.144		80/TCP
cic-watcher	ingress-basic	Ok	ClusterIP	10.0.189.68		80/TCP
cic-logger	ingress-basic	Ok	ClusterIP	10.0.255.25		80/TCP

Abbildung 4: Liste der ClusterIPs / LoadBalancer

Middleware - D

Die Middleware ist das zentrale Element der Infrastruktur. Alle Abfragen vom Frontend laufen über die Middleware. Die Middleware koordiniert die Überwachung der Kosten mit dem Watcher, wandelt Sprachaufnahmen in Texte um über den speech-to-text Service, generiert Embeddings für Texte mit dem ALBERT Service und gibt Empfehlungen zurück an das Frontend.

Watcher - E

Der Watcher überwacht die anfallenden Kosten des Clusters. Bei jeder Anfrage an die Middleware, wird von dieser geprüft, ob noch Budget vorhanden ist. Die Anfragen, welche an den Watcher gestellt werden, werden in einer Azure Cosmos DB persistiert. Damit können später auch Analysen und Auswertungen durchgeführt werden. Administratoren haben die Möglichkeit über einen API-Client (z.B. Postman) Einstellungen am Watcher vorzunehmen, oder das aktuell verbrauchte Budget einzusehen. Diese Endpunkte benötigen eine speziellen Admin-Token um aufgerufen werden zu können.

Logging System - F

Das Loggingsystem besteht aus zwei verschiedenen Use Cases. Zum einen kann über (https://api.moviematch.ch/cic-logger/status) der Status und die Latenz der anderen beiden Workloads abgefragt werden. Zusätzlich wird alle fünf Minuten probiert eine Verbindung zu den beiden Workflows aufzubauen. Dabei wird die Latenz der beiden Workloads gemessen. Diese Ergebnisse werden auch in die Azure Cosmos DB geloggt.

Azure Cosmos DB - G

Der Azure Cosmos DB Cluster wird als serverless NoSQL-Variante betrieben und besteht aus zwei Datenbanken (cic-watcher und cic-logger). Auf den beiden Datenbanken befinden sich jeweils Collections, welche auf die jeweiligen Use Case des Workloads zugeschnitten sind.

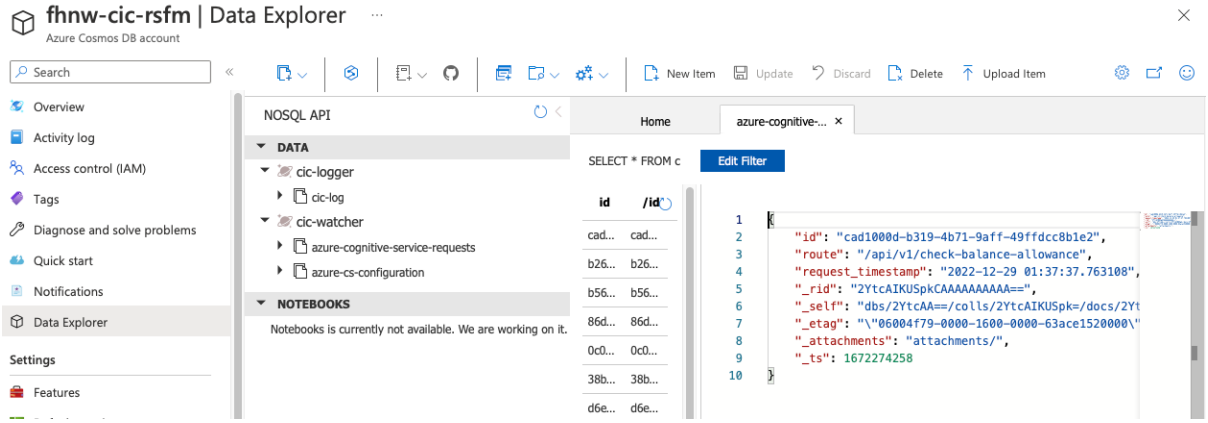

Abbildung 5: Screenshot Azure Cosmos DB mit 2 Datenbanken

Mock Option - H

Die Mock Option beinhaltet eine vereinfachte Variante des Cognitive Services Speech-to-Text. Sie wurde zur Ersparnis von Kosten bei der Entwicklung verwendet. So müssen nicht immer Anfragen an den teureren Cognitive-Service geschickt werden. Sie können einfach an die Mock Option umgeleitet werden, welche die Anfrage überprüft und bei Erfolg immer den gleichen Wert zurückschickt.

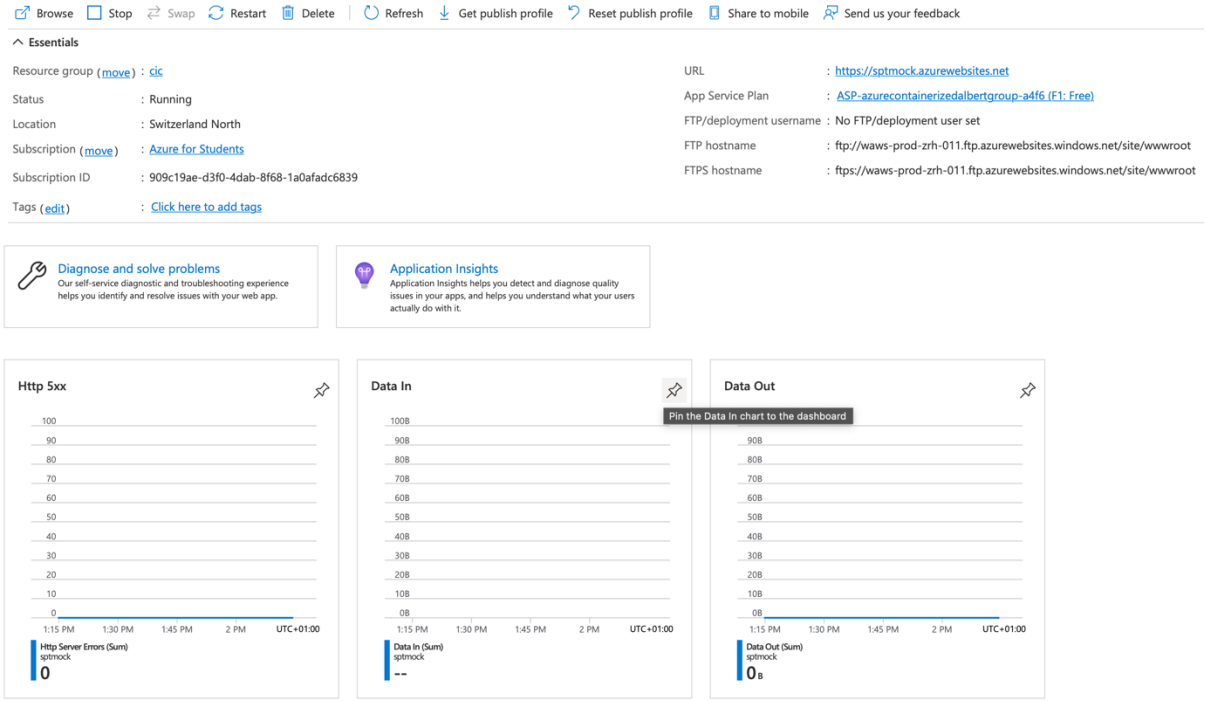

Abbildung 6, Mock Option Deployment

ALBERT - I

Das Sprachmodell ALBERT wurde in eine Flask-API integriert. Die API erledigt das Preprocessing der Texte und wandelt sie in Embeddings um. Die API ist in einem Dockercontainer verpackt. Dieser Container wurde als Azure App Service eingesetzt. Die API ist unter folgender URL erreichbar: https://azure-containerized-albert.azurewebsites.net. Der Container wurde wegen folgenden Gründen nicht auf Kubernetes eingesetzt: Die Studentenversion erlaubt nur zwei Pods mit öffentlichen IP-Addressen. Wir entschieden uns deshalb die zwei wichtigeren Services, die Middleware und den Watcher, auf Kubernetes einzusetzen. Wir versuchten auch die API mit ALBERT in die Middleware zu integrieren. Da das Sprachmodell aber so gross ist, dass eine stärkere und teurere Maschine nötig gewesen wäre, entschieden wir uns dagegen. Die generierten Kosten der teureren Maschine wären mit dem 100 CHF Kredit des Studentenaccounts nicht tragbar gewesen.

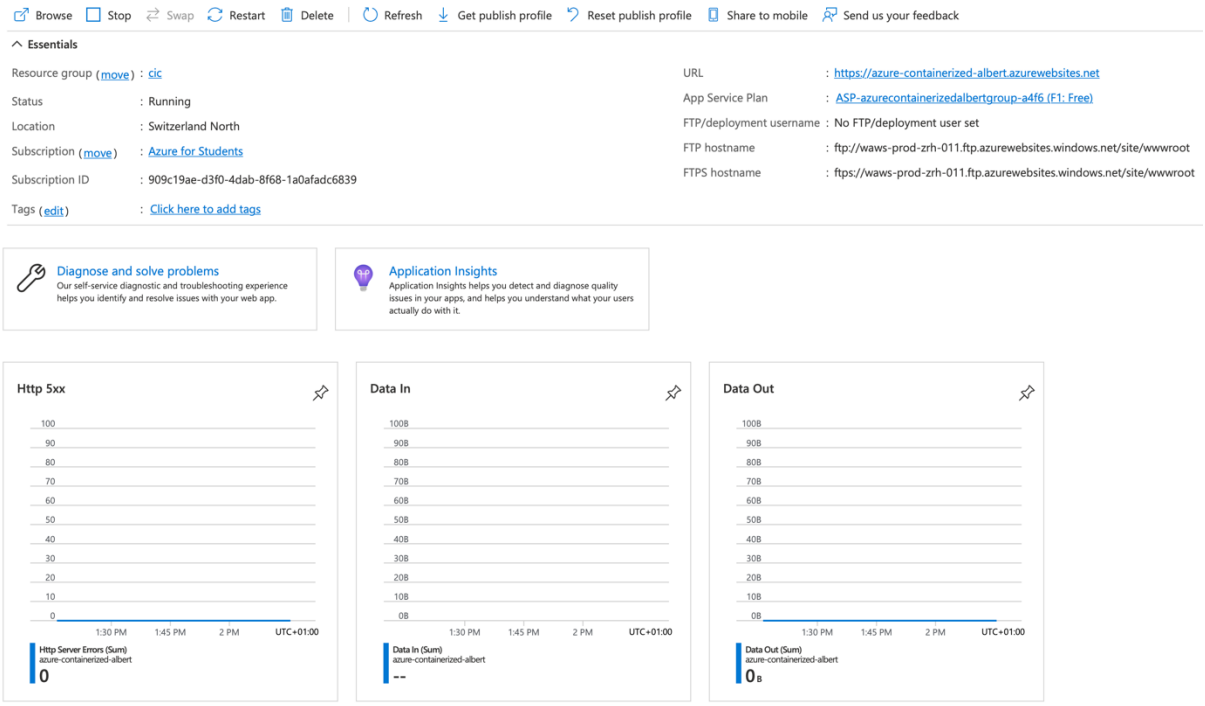

Abbildung 7, ALBERT Deployment

Speech-to-text - J

Speecht-to-text ist ein Cognitive Service von Azure und kann als Cognitive Service in Ressourcengruppen gestartet werden. Danach können http Abfragen an den Service geschickt werden, die ein .wav File enthalten. Als Antwort kommt dann der erkannte Text zurück.

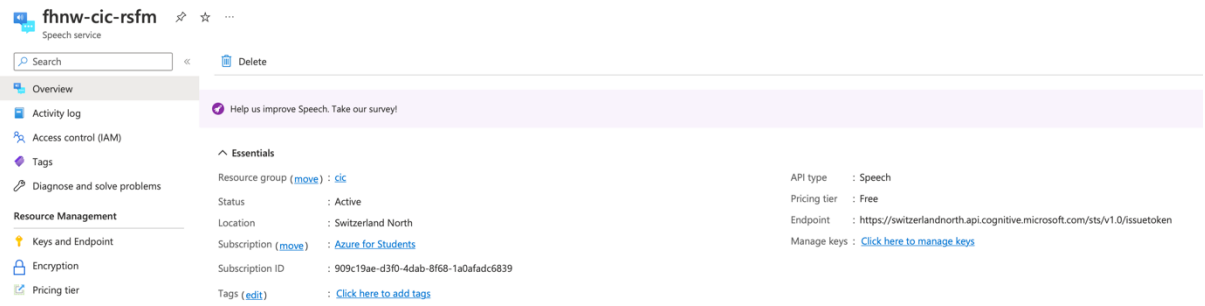

Abbildung 8, Speech-to-Text Deployment

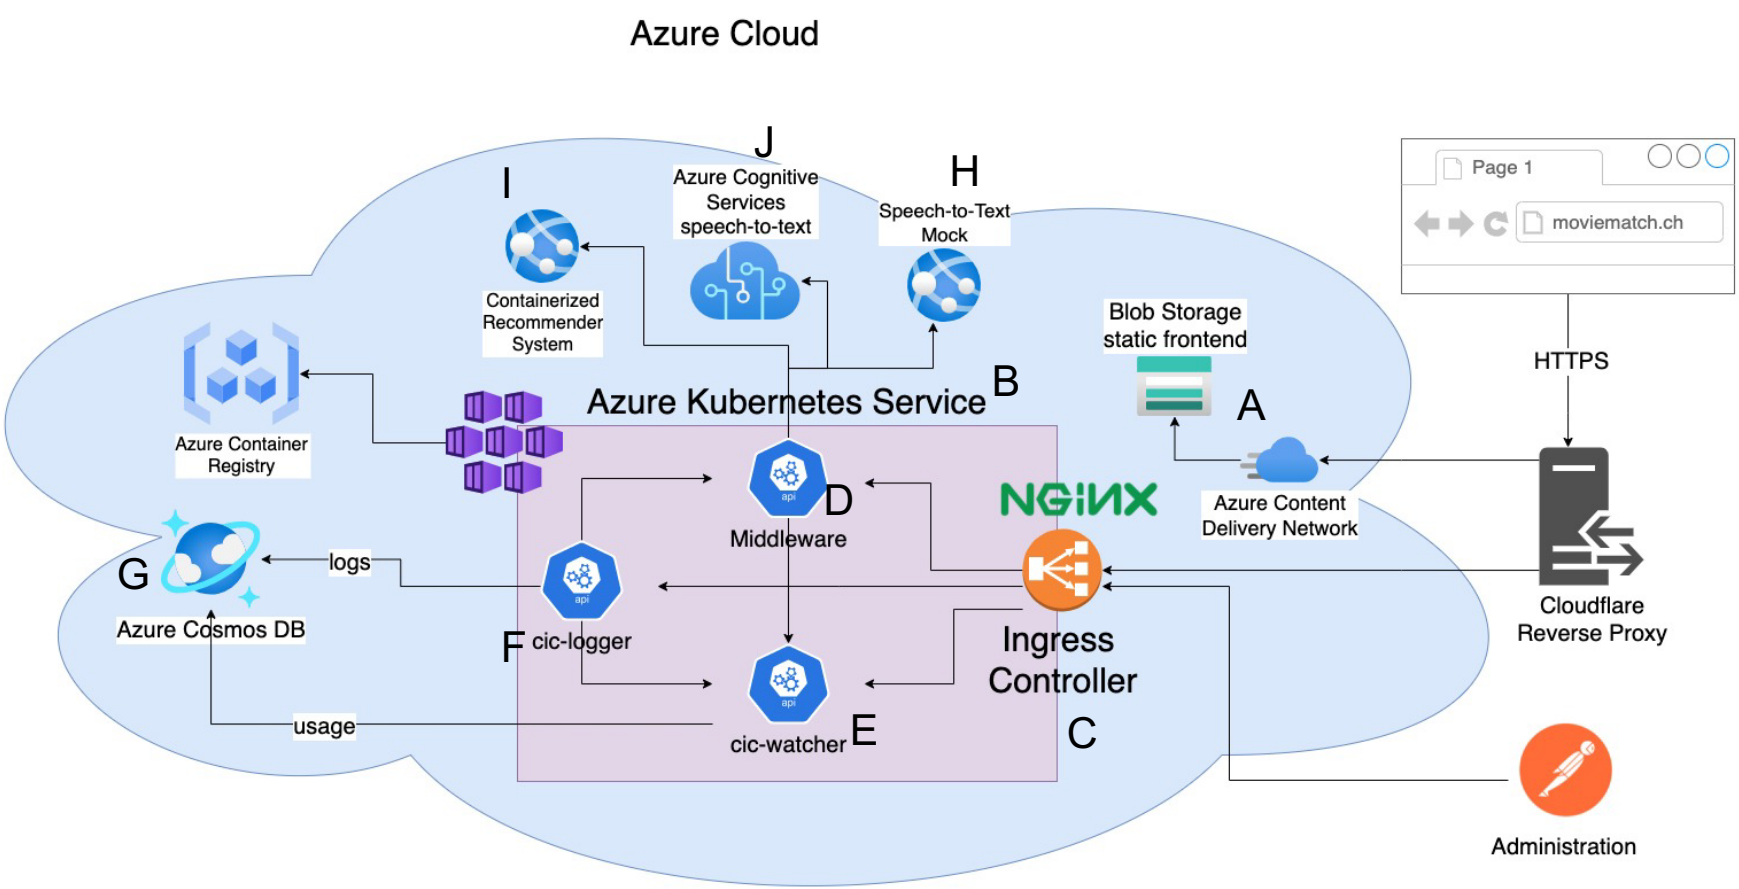
Azure Cloud
J
Azure Cognitive Services speech-to-text
I
Containerized Recommender System
H
Speech-to-Text Mock
Page 1
moviematch.ch
Blob Storage static frontend
HTTPS
Azure Container Registry
Azure Kubernetes Service
B
A
Azure Content Delivery Network
D
Middleware
NGINX
G
logs
Azure Cosmos DB
F
cic-logger
Ingress Controller
Cloudflare Reverse Proxy
usage
cic-watcher
E
C
Administration

Funktionsabläufe Abfragen

Wie bereits erwähnt gibt es zwei mögliche Abfragen, die vom Frontend an die Middleware geschickt werden. Die Abläufe der beiden Abfragen werden detailliert beschrieben.

Empfehlung durch Nutzerprofil – 1

Wenn ein Nutzerprofil erstellt worden ist, können die ids der Filme, die der Benutzer als positiv bewertet hat, an die Middleware geschickt werden. Die Antwort enthält Empfehlungen. Die Anfrage wird wie folgt bearbeitet:

1. Anfrage an Watcher, Überprüfung Kostenlimit
2. Überprüfung des Keys
3. Überprüfung der Daten
4. Berechnung und Rückgabe der Empfehlungen

Empfehlung durch Sprachaufnahme – 2

Wenn der Benutzer im Frontend eine Sprachaufnahme erstellt hat und sie abschickt, geschieht in der Middleware folgendes:

1. Anfrage an Watcher, Überprüfung Kostenlimit
2. Überprüfung des Keys
3. Anfrage an speech-to-text Service
4. Text von Speech-to-text an ALBERT schicken
5. Distanzen zwischen Embedding von ALBERT und Filmbeschreibungen berechnen
6. Empfehlungen zurückgeben

Deployment der Services auf Azure

Die folgende Tabelle liefert einen Überblick, wo welche Services eingesetzt wurden.

Servicename	**Verwendeter Service**
azure-containerized-albert	Azure App Service
Speech-to-text	Azure Speech Service
Middleware	Kubernetes Workload
Watcher	Kubernetes Workload
Logger	Kubernetes Workload
Ingress Controller	Kubernetes Ingress

Die folgende Tabelle liefert einen Überblick, auf welche Art die Services eingesetzt wurden.

Servicename	**Beschreibung**
azure-containerized-albert	Flask-API in Dockercontainer. Deployment und Konfiguration im Azure-Portal.

Speech-to-text	Kein Programmieraufwand. Deployment und Konfiguration im Azure-Portal.
Middleware	Flask-API im Dockercontainer. Deployment und Konfiguration via deployment.yml Datei.
Watcher	Flask-API im Dockercontainer. Deployment und Konfiguration via deployment.yml Datei.
Logger	Flask-API im Dockercontainer. Deployment und Konfiguration via deployment.yml Datei
Ingress Controller	Installiert via Helm direkt auf dem Cluster. Konfiguriert via .yml File

Fazit Entwicklungsprozess